

Instituto Tecnológico de Costa Rica.

Programa de Ciencia de Datos.

Módulo V

Anteproyecto
Inteligencia de Negocios para
Chinook Digital Media Store

Estudiantes:

Roberto Baltodano García
Sergio Blanzo Zeledón

mayo 2026

Tabla de Contenido

1. Fase de Entendimiento del Negocio..... 3

 Objetivos y criterios de éxito 3

2. Sistemas de información 3

3. Requerimientos de información 4

4. Descripción de la base de datos (justificación de tablas y campos)..... 4

1. Fase de Entendimiento del Negocio

En esta fase se establece el marco estratégico y comercial que guiará el desarrollo de la solución analítica.

Para el acceso a la información de Chinook Digital Media Store se debe acceder al siguiente enlace: <https://github.com/lerocha/chinook-database>

Objetivos y criterios de éxito

Objetivo general:

- Desarrollar una solución analítica multidimensional basada en un almacén de datos (Data Warehouse) bajo la metodología CRISP-DM para la base de datos transaccional de Chinook Digital Media Store, con el fin de proporcionar herramientas de Inteligencia de Negocios que optimicen la rotación del catálogo musical e identifiquen segmentos de clientes de alto valor estratégico.

Objetivos específicos:

- **Objetivo de negocio 1:** Optimizar el catálogo de medios digitales mediante la identificación y reducción de productos con baja rotación de inventario virtual (pistas musicales y álbumes sin ventas).
- **Criterio de éxito 1.1:** Lograr clasificar el 100% del catálogo musical actual en categorías de rendimiento comercial (Alto, Medio, Crítico/Sin Ventas) basándose en el histórico de los últimos 4 años.
- **Criterio de éxito 1.2:** Proveer al departamento de adquisiciones un listado automatizado de los 50 artistas y géneros menos rentables para congelar compras de nuevas licencias o renegociar contratos de distribución, buscando reducir costes de almacenamiento o licenciamiento inactivo en al menos un **15%**.
- **Objetivo de negocio 2:** Maximizar los ingresos por ventas recurrentes a través de la retención y fidelización de clientes de alto valor (estrategia de clientes *VIP*).
- **Criterio de éxito 2.1:** Diseñar un modelo de segmentación que identifique de forma precisa al **top 10%** de los clientes que generan el mayor volumen de facturación acumulada por región geográfica.
- **Criterio de éxito 2.2:** Generar la base de datos de clientes objetivo para que el equipo de marketing digital despliegue campañas de promociones personalizadas (por ejemplo, cupones para sus géneros musicales preferidos), apuntando a un incremento de un **5%** en el ticket promedio de compra en el siguiente trimestre.

2. Sistemas de información

Esta sección detalla el origen de los datos y el ecosistema transaccional actual del cual se nutrirá nuestra solución.

- **Nombre de la base de datos:** Chinook (disponible y compatible nativamente en motores relacionales como SQL Server, Oracle, MySQL, PostgreSQL, SQLite y DB2).

- **Tema o naturaleza de los datos:** Se trata de un sistema transaccional (OLTP) que administra las operaciones de una tienda de música digital. Maneja flujos de información que vinculan catálogos multimedia (canciones, álbumes, artistas, géneros), estructuras corporativas (empleados y asignación de soporte a clientes) y el registro detallado de las transacciones de venta internacionales (facturas y líneas de detalle) con clientes localizables geográficamente.

3. Requerimientos de información

Para dar soporte a los objetivos de negocio planteados, el almacén de datos (Data Warehouse) deberá ser capaz de resolver y responder de manera ágil los siguientes interrogantes analíticos:

1. ¿Cuáles son las pistas musicales (Tracks) y álbumes que no han registrado ninguna venta a lo largo de todo el histórico disponible, y a qué artistas y géneros pertenecen? (Orientado al Objetivo de Negocio 1).
2. ¿Qué géneros musicales específicos han sufrido una desaceleración o disminución sostenida en sus ventas globales durante el último semestre de registros? (Orientado al Objetivo de Negocio 1).
3. ¿De qué países, estados y ciudades provienen los clientes que han incrementado consecutivamente su volumen de compra año tras año? (Orientado al Objetivo de Negocio 2).
4. ¿Quiénes son los clientes específicos que componen el grupo de mayor valor (mayor facturación acumulada) y qué empleados de soporte (Employees) están a cargo de su atención directa? (Orientado al Objetivo de Negocio 2).

4. Descripción de la base de datos (justificación de tablas y campos)

Para dar solución estricta a los requerimientos de información planteados en el punto anterior, se seleccionarán y justificarán las siguientes tablas del ecosistema de Chinook:

Tabla	Campos clave seleccionados	Justificación de uso
Track	TrackId, Name, AlbumId, GenreId, UnitPrice	Es el núcleo del catálogo musical. Permite cruzar e identificar cuáles canciones específicas se están vendiendo y cuáles tienen nula rotación.
Album	AlbumId, Title, ArtistId	Permite agrupar las canciones por producción discográfica para evaluar si existen álbumes completos sin rendimiento comercial.
Artist	ArtistId, Name	Esencial para identificar y listar a los creadores o bandas de la música sin ventas para la toma de decisiones contractuales.

Tabla	Campos clave seleccionados	Justificación de uso
Genre	GenreId, Name	Permite categorizar el comportamiento de las ventas y detectar macro-tendencias (cuáles géneros musicales están en declive o crecimiento).
Invoice	InvoiceId, CustomerId, InvoiceDate, BillingCountry, BillingState, BillingCity, Total	Contiene la metadata transaccional básica de tiempo y geografía. Es indispensable para calcular la facturación total y analizar el comportamiento de las ventas por país/estado a lo largo del tiempo.
InvoiceLine	InvoiceLineId, InvoiceId, TrackId, Quantity, UnitPrice	Detalle granular de las compras. Permite verificar la cantidad de unidades vendidas de cada pista individual y validar matemáticamente la ausencia de registros de los productos sin rotación.
Customer	CustomerId, FirstName, LastName, Country, State, City, SupportRepId	Almacena los perfiles de los compradores. Crucial para la segmentación de clientes VIP y el análisis de la distribución geográfica del incremento de ventas.
Employee	EmployeeId, FirstName, LastName, Title	Permite mapear al personal interno involucrado en la atención y retención de los clientes que generan el mayor valor al negocio.

Requerimiento 1

¿Cuáles son las pistas musicales (Tracks) y álbumes que no han registrado ninguna venta a lo largo de todo el histórico disponible, y a qué artistas y géneros pertenecen?

- Tablas Principales Requeridas:**

- Track:** Contiene la lista total de canciones licenciadas por la tienda digital. Es la tabla base sobre la cual se debe realizar una exclusión lógica (e.g., LEFT JOIN o NOT IN) para verificar qué identificadores (TrackId) no figuran en las transacciones comerciales.

- **InvoiceLine:** Almacena el detalle granular de los artículos vendidos. Es la tabla obligatoria para comprobar la ausencia de registros de compra de las canciones inactivas.
- **Tablas Secundarias (Estructurales de Dimensión):**
 - **Album:** Requerida para agrupar e identificar las producciones completas que no generan rendimiento comercial.
 - **Artist:** Necesaria para asociar el nombre del creador o banda con el álbum y la pista sin ventas.
 - **Genre:** Indispensable para categorizar las pistas huérfanas de venta según su género musical.

Requerimiento 2

¿Qué géneros musicales específicos han sufrido una desaceleración o disminución sostenida en sus ventas globales durante el último semestre de registros?

- **Tablas Principales Requeridas:**
 - **Invoice:** Proporciona el encabezado de la facturación con el atributo temporal clave (InvoiceDate). Es indispensable para poder filtrar las transacciones por semestres y años históricos, permitiendo calcular la desaceleración del negocio.
 - **InvoiceLine:** Contiene los montos unitarios (UnitPrice) y las cantidades transaccionadas (Quantity) para calcular el volumen total de ingresos.
 - **Genre:** Contiene el nombre del género musical (Name). Al unirse con el detalle de venta, permite consolidar y comparar los ingresos agregados de cada categoría musical a lo largo del tiempo.
- **Tablas Secundarias:**
 - **Track:** Actúa únicamente como puente relacional intermedio para conectar la línea de detalle de la venta (InvoiceLine) con su respectivo género (Genre).

Requerimiento 3

¿De qué países, estados y ciudades provienen los clientes que han incrementado consecutivamente su volumen de compra año tras año?

- **Tablas Principales Requeridas:**
 - **Invoice:** Registra tanto los montos de facturación (Total) como la fecha de emisión (InvoiceDate) para realizar agrupaciones por periodos anuales. Además, almacena los campos geográficos de destino del envío (BillingCountry, BillingState, BillingCity).
 - **Customer:** Contiene los perfiles de los compradores. Aunque la tabla Invoice posee datos geográficos de facturación, la tabla de clientes es crucial para validar y

estructurar la dimensión demográfica base del comprador (Country, State, City) y agrupar el comportamiento recurrente a nivel de entidad.

Requerimiento 4

¿Quiénes son los clientes específicos que componen el grupo de mayor valor (mayor facturación acumulada) y qué empleados de soporte (Employees) están a cargo de su atención directa?

- **Tablas Principales Requeridas:**

- **Customer:** Aporta la identidad directa de los compradores (FirstName, LastName) para listar formalmente el top de la cartera de clientes de alto valor. Posee la llave foránea (SupportRepld) que la conecta con su gestor corporativo.
- **Invoice:** Contiene el campo de valor total (Total) por cada compra individual, el cual debe ser procesado mediante una función de agregación (SUM) para calcular el gasto acumulado histórico por cliente.
- **Employee:** Almacena los registros del personal interno (FirstName, LastName, Title). Es la tabla requerida para identificar con nombre y apellido a los representantes de soporte que atienden de forma directa al segmento de clientes VIP.

Resumen para el Almacén de Datos

Para el diseño físico de las canalizaciones **ETL** y la posterior carga de datos en un **Esquema Multidimensional**, tu proyecto necesitará extraer de manera estricta la información de **8 tablas operativas** del entorno Chinook: Track, Album, Artist, Genre, Invoice, InvoiceLine, Customer y Employee. Esto asegura la cobertura del 100% de los requerimientos analíticos planteados en el anteproyecto.

ATRIBUTOS DE CADA TABLA.

Basado en la estructura física DDL de la base de datos transaccional **Chinook** y cruzándolo de manera estricta con el documento de **Propuesta de Anteproyecto**, a continuación se desglosan los atributos mínimos y necesarios (llaves primarias, foráneas y campos descriptivos o métricas) requeridos para dar solución analítica a cada requerimiento de información:

Requerimiento de Información 1

¿Cuáles son las pistas musicales (Tracks) y álbumes que no han registrado ninguna venta a lo largo de todo el histórico disponible, y a qué artistas y géneros pertenecen?

Para resolver la ausencia de compras mediante una consulta de exclusión (tipo NOT IN o LEFT JOIN), se necesitan mapear las estructuras de catálogo e interconectarlas con el detalle transaccional mediante los siguientes atributos:

- **Track:**
 - TrackId (*Llave Primaria*): Atributo clave para verificar la existencia o ausencia del producto en la tabla de ventas.
 - Name (*Atributo Descriptivo*): Nombre de la canción o pista que se va a listar.
 - AlbumId (*Llave Foránea*): Permite conectar la canción con su respectivo álbum.
 - GenreId (*Llave Foránea*): Permite conectar la canción con su respectiva categoría o género musical.
- **InvoiceLine:**
 - TrackId (*Llave Foránea*): Atributo fundamental para constatar qué canciones **sí** han tenido transacciones comerciales.
- **Album:**
 - AlbumId (*Llave Primaria*): Código identificador del disco.
 - Title (*Atributo Descriptivo*): Nombre o título de la producción discográfica a reportar.
 - ArtistId (*Llave Foránea*): Permite enlazar el álbum al autor o banda correspondiente.
- **Artist:**
 - ArtistId (*Llave Primaria*): Código único del artista.
 - Name (*Atributo Descriptivo*): Nombre de la banda o solista.
- **Genre:**
 - GenreId (*Llave Primaria*): Código único del género.
 - Name (*Atributo Descriptivo*): Nombre descriptivo de la categoría musical (ej. Rock, Jazz).

Requerimiento de Información 2

¿Qué géneros musicales específicos han sufrido una desaceleración o disminución sostenida en sus ventas globales durante el último semestre de registros?

Este análisis requiere cálculos de tendencias temporales y consolidación de ingresos monetarios agregados por categoría, por lo que se necesitan los siguientes atributos:

- **Invoice:**
 - InvoiceId (*Llave Primaria*): Conector directo con la línea de detalle.
 - InvoiceDate (*Atributo de Tiempo/Fecha*): Atributo indispensable para agrupar las transacciones en semestres y años, permitiendo evaluar el comportamiento histórico y la desaceleración del negocio.
- **InvoiceLine:**

- InvoiceId (*Llave Foránea*): Relación con la cabecera de la factura.
 - TrackId (*Llave Foránea*): Puente relacional para llegar a la clasificación musical.
 - UnitPrice (*Métrica / Valor Monetario*): Precio unitario de la pista al momento de la venta.
 - Quantity (*Métrica / Volumen*): Cantidad de unidades adquiridas (usada en conjunto con UnitPrice para calcular los ingresos generados).
- **Track:**
 - TrackId (*Llave Primaria*): Identificador de la pista.
 - GenreId (*Llave Foránea*): Enlace final hacia el nombre de la categoría.
 - **Genre:**
 - GenreId (*Llave Primaria*): Identificador del género.
 - Name (*Atributo Descriptivo*): Nombre del género musical sobre el cual se calculará el declive de ingresos globales.

Requerimiento de Información 3

¿De qué países, estados y ciudades provienen los clientes que han incrementado consecutivamente su volumen de compra año tras año?

Este interrogante requiere comparar el rendimiento total por cliente en periodos anuales segregándolos bajo agrupaciones geográficas, utilizando los siguientes campos:

- **Invoice:**
 - CustomerId (*Llave Foránea*): Permite agrupar las transacciones recurrentes por cliente individual.
 - InvoiceDate (*Atributo de Tiempo*): Permite extraer el año de la venta para evaluar el incremento o decremento consecutivo anual.
 - Total (*Métrica*): Monto monetario total de la factura que sirve para sumarizar y contrastar el volumen financiero anual por comprador.
- **Customer:**
 - CustomerId (*Llave Primaria*): Identificador del cliente para consolidar su perfil único.
 - Country (*Atributo Geográfico*): País de procedencia del cliente.
 - State (*Atributo Geográfico*): Estado o provincia de origen (esencial para jerarquías multidimensionales).
 - City (*Atributo Geográfico*): Ciudad de residencia del consumidor.

(Nota: Aunque la tabla Invoice posee campos de facturación geográfica como BillingCountry, se prioriza la tabla Customer para asegurar que el análisis demográfico se construya con base en los perfiles maestros de la cartera activa y no en direcciones variables de envío).

Requerimiento de Información 4

¿Quiénes son los clientes específicos que componen el grupo de mayor valor (mayor facturación acumulada) y qué empleados de soporte (Employees) están a cargo de su atención directa?

Para este análisis de segmentación de clientes VIP y auditoría de asignación interna de soporte de ventas, los atributos requeridos son:

- **Customer:**
 - CustomerId (*Llave Primaria*): Identificador maestro del cliente.
 - FirstName (*Atributo Descriptivo*): Primer nombre del comprador.
 - LastName (*Atributo Descriptivo*): Apellido del comprador.
 - SupportRepId (*Llave Foránea*): Campo relacional crítico que conecta al cliente de manera jerárquica con su representante de soporte asignado.
- **Invoice:**
 - CustomerId (*Llave Foránea*): Conexión para acumular los montos de compra.
 - Total (*Métrica*): Campo numérico sobre el cual se aplicará una función de agregación (SUM(Total)) para clasificar a los clientes según su valor financiero de vida.
- **Employee:**
 - EmployeeId (*Llave Primaria*): Identificador único del empleado que se mapea contra el campo SupportRepId de la tabla de clientes.
 - FirstName (*Atributo Descriptivo*): Nombre del representante asignado a la cuenta VIP.
 - LastName (*Atributo Descriptivo*): Apellido del representante analizado.
 - Title (*Atributo Descriptivo*): Cargo o puesto dentro de la organización corporativa (ej. *Sales Support Agent*) para validar su rol operativo.

Para la BD DW se describe los campos que se eliminan,

Sí, al revisar en detalle el esquema de la base de datos Chinook_Analisis provisto en el archivo

Script_BD_Stage-v2.txt, se identifican varios campos específicos en las tablas que **no son necesarios** ni se consumen en ninguna de las cuatro preguntas analíticas planteadas.

A continuación, se detallan cuáles son esos campos sobrantes por cada tabla y por qué no se requieren para los objetivos de negocio:

1. Tabla Employee (Empleados)

- **Campos sobrantes:** Title (Cargo/Puesto).
- **Razón:** La **Pregunta 4** solo pide identificar qué empleados de soporte (Employees) están a cargo de la atención directa de los clientes de mayor valor. Para responder esto, solo se necesitan sus datos de identidad (FirstName, LastName) y su identificador (EmployeeId) para realizar el acoplamiento con la tabla de clientes. El cargo o título del empleado no aporta valor a dicha consulta.

2. Tabla Track (Pistas Musicales)

- **Campos sobrantes:** UnitPrice (Precio Unitario de la Pista).
- **Razón:** * Para la **Pregunta 1** (pistas sin ventas), solo se requiere verificar la existencia o ausencia del TrackId en las transacciones.
- Para la **Pregunta 2** (desaceleración de géneros), el análisis financiero de los ingresos y cantidades se debe realizar directamente sobre los campos UnitPrice y Quantity de la tabla **InvoiceLine**. El precio en la tabla Track es el valor de lista actual, pero el cálculo real de ventas históricas siempre se extrae de la línea de la factura para reflejar lo que verdaderamente pagó el usuario.

3. Tabla Invoice (Facturas)

- **Campos sobrantes:** BillingCity (Ciudad de Facturación), BillingState (Estado de Facturación) y BillingCountry (País de Facturación).
- **Razón:** La **Pregunta 3** pide evaluar el origen geográfico de los *clientes* que incrementan sus compras año tras año. Esta información de procedencia se debe extraer de los atributos nativos de localización del cliente en la tabla Customer (City, State, Country). Los campos de facturación (Billing...) de la tabla Invoice registran el destino del cobro, el cual puede diferir de la residencia fiscal u origen del cliente, haciéndolos innecesarios para este requerimiento geográfico específico.

Resumen desde la Perspectiva de Inteligencia de Negocios (BI)

En el diseño de un proceso de carga de datos (ETL/ELT) hacia un Data Warehouse o un modelo analítico, identificar estos campos es clave. Los atributos como Title (en Employee), UnitPrice (en Track) y los datos de Billing (en Invoice) representan **datos redundantes o ruido analítico** para este pliego de preguntas específico. Podrían excluirse en la fase de transformación si se deseara optimizar al máximo el almacenamiento y la claridad del modelo final.

Ventajas de este Script Depurado:

1. **Ahorro de almacenamiento y memoria:** Al remover campos extensos de texto como las direcciones de facturación y puestos, se reduce el tamaño físico de las páginas de datos en el disco y en el buffer pool de la memoria RAM.
2. **Rendimiento en los JOIN:** Los índices creados al final ahora incluyen (INCLUDE) las columnas métricas exactas (UnitPrice, Quantity, CustomerId, Total). Esto significa que las consultas analíticas complejas que involucren semestres o agrupaciones geográficas anuales se resolverán mediante un **Index Seek** de alta velocidad, evitando tocar la tabla base (*Key Lookup*).